Food.com Recipes and Interactions

Anja Petrović 168/2022

Marina Nešković 184/2022

Sadržaj

1. Analiza i priprema Food.com Recipes and Interactions skupa podataka 3
1.1. Uvod 3
1.2. Priprema i inicijalna analiza podataka 3
1.3. Čišćenje podataka i analiza distribucija 4
2. Klasterovanje 6
2.1. Klasterovanje numeričkih podataka 6
2.2. Klasterovanje tekstualnih recenzija 7
2.3. Zaključak 7
3. Klasifikacija 8
3.1. Klasifikacija na nivou korisničkih recenzija 8
3.2. 9
3.3. Zaključak 9

1. Analiza i priprema Food.com Recipes and Interactions skupa podataka

1.1. Uvod

U okviru ovog projekta analiziran je skup podataka *Food.com Recipes and Interactions*, koji sadrži informacije o receptima, sastojcima, nutritivnim vrednostima, kao i interakcijama korisnika kroz ocene i komentare. Dataset predstavlja realan primer velikog i heterogenog skupa podataka, koji obuhvata numeričke, kategorijske i tekstualne atribute, što ga čini pogodnim za primenu različitih metoda analize podataka i mašinskog učenja.

Osnovni cilj rada bio je izgradnja kompletnog pipeline-a obrade podataka koji uključuje faze pretprocesiranja, klasifikacije i klasterovanja recepata. Poseban fokus stavljen je na praktičnu pripremu podataka, konstrukciju novih atributa i stabilizaciju raspodela, kako bi se obezbedio kvalitetan ulaz za kasnije modele.

Skup podataka sastoji se iz dva glavna dela: podataka o receptima, koji uključuju opisne karakteristike poput trajanja pripreme, broja koraka, sastojaka i nutritivnih vrednosti, i podataka o korisničkim interakcijama, koji sadrže ocene i tekstualne recenzije. Kombinovanjem ova dva izvora omogućena je detaljnija analiza strukture recepata i ponašanja korisnika.

Rad je organizovan kroz nekoliko faza: inicijalnu analizu i čišćenje podataka, transformaciju atributa i konstrukciju novih karakteristika, kao i pripremu finalnih skupova podataka namenjenih klasifikaciji i klasterovanju.

1.2. Priprema i inicijalna analiza podataka

U početnoj fazi izvršeno je učitavanje Food.com skupa podataka korišćenjem biblioteka *pandas*, *numpy*, *matplotlib* i alata iz biblioteke *scikit-learn*. Biblioteka *ast* korišćena je za parsiranje atributa koji su zapisani kao liste u tekstualnom formatu.

Učitana su dva osnovna skupa: podaci o receptima (RAW_recipes.csv) i podaci o korisničkim interakcijama (RAW_interactions.csv). Nakon učitavanja izvršen je pregled prvih redova, dimenzija i tipova atributa radi razumevanja strukture podataka.

Analizom nedostajućih vrednosti utvrđeno je da se najveći broj praznih zapisa pojavljuje u atributu *description*, dok su ostali atributi uglavnom kompletni. Recepti bez naziva uklonjeni su iz daljeg razmatranja. Takođe je izvršena osnovna statistička analiza numeričkih atributa, pri čemu je uočena izražena asimetrija raspodele, posebno kod atributa *minutes*, što je ukazivalo na prisustvo ekstremnih vrednosti.

1.3. Čišćenje podataka i analiza distribucija

U sledećem koraku izvršeno je dodatno čišćenje skupa recepata. Nedostajuće vrednosti u tekstualnim atributima zamenjene su praznim stringom kako bi se omogućila dalja obrada bez gubitka zapisa. Proverena je i jedinstvenost identifikatora recepata, čime je potvrđeno da svaki zapis poseduje jedinstven ID.

Vizuelizacija atributa *minutes* putem boxplot dijagrama ukazala je na veliki broj ekstremnih vrednosti. Uvedena je gornja granica od 1440 minuta kako bi se uklonili nerealni outlieri, dok su vrednosti jednake nuli zamenjene minimalnom vrednošću od jednog minuta. Nakon filtriranja izvršena je ponovna analiza distribucije korišćenjem violin plot vizuelizacije, čime je potvrđeno stabilizovanje raspodele.

Distribucije broja koraka i broja sastojaka analizirane su histogramima, pri čemu je uočena blaga desna asimetrija, odnosno dominacija recepata sa manjim brojem koraka i sastojaka.

U nastavku je izvršena transformacija pojedinih atributa radi dobijanja numeričkog oblika pogodnog za modele mašinskog učenja. Atribut *submitted* konvertovan je u vremenski format, dok je iz atributa *tags* izdvojen broj tagova po receptu.

Posebna pažnja posvećena je atributu *nutrition*, koji je parsiran i razdvojen na više numeričkih kolona: kalorije, masti, šećer, natrijum, proteine, zasićene masti i ugljene hidrate. Vizuelizacijom nutritivnih atributa uočene su ekstremne vrednosti, pa su uklonjeni zapisi sa nerealno velikim kalorijskim vrednostima, čime je smanjen uticaj outliera.

Nakon obrade recepata fokus je prebačen na skup korisničkih interakcija. Izvršeno je dodatno čišćenje nedostajućih vrednosti i analiza raspodele ocena, pri čemu je uočeno da dominiraju visoke ocene, posebno ocena 5. Takođe je potvrđeno postojanje zapisa sa ocenom nula i praznim tekstom recenzije, koji su tretirani kao validni.

Proverena je konzistentnost između tabela *recipes* i *interactions*, pri čemu je utvrđeno da manji broj ocena referencira recepte koji ne postoje u osnovnom skupu. Ovi zapisi su izdvojeni i analizirani kako bi se identifikovali potencijalni izvori šuma.

Nakon validacije izvršeno je spajanje tabela *interactions* i *recipes* korišćenjem identifikatora recepta. Kako jedan recept može imati više recenzija, izvršena je agregacija podataka grupisanjem po identifikatoru recepta. Uvedene su dve nove karakteristike: prosečna ocena (*avg_rating*) i broj ocena (*num_ratings*), čime je svaki recept predstavljen jedinstvenim zapisom sa agregiranim informacijama.

Formiran je objedinjeni skup podataka koji sadrži nutritivne atribute, opisne karakteristike recepata i agregirane informacije o korisničkim interakcijama, čime je pripremljena osnova za dalju analizu.

Kako bi atribut *ingredients* bio pogodan za algoritme mašinskog učenja, izvršena je transformacija liste sastojaka u binarnu reprezentaciju primenom metode One-Hot kodiranja uz pomoć klase *MultiLabelBinarizer*. Za svaki jedinstveni sastojak formirana je posebna kolona koja označava njegovo prisustvo u receptu.

Zbog velikog broja sastojaka korišćena je sparse reprezentacija matrice radi smanjenja memorijske potrošnje. Analizom frekvencije pojavljivanja uočeno je da veliki broj sastojaka ima veoma malu zastupljenost, pa su retki sastojci uklonjeni kako bi se smanjila dimenzionalnost i poboljšala stabilnost modela.

Na kraju su formirana dva skupa podataka — jedan sa svim sastojcima i drugi sa svim recenzijama — koji su sačuvani u binarnom formatu radi bržeg učitavanja u narednim fazama projekta.

2. Klasterovanje

Cilj klaster analize bio je identifikovanje prirodnih grupa unutar skupa podataka bez unapred definisanih oznaka. Klasterovanje je primenjeno nad:

- numeričkim karakteristikama recepata
- tekstualnim recenzijama korisnika

Na taj način analizirana je struktura podataka i utvrđeno da li postoje smisleni obrasci u ponašanju korisnika i karakteristikama recepata.

2.1. Klasterovanje numeričkih podataka

Za klasterovanje su korišćene numeričke karakteristike recepata, uključujući nutritivne vrednosti, kalorije, masti, šećer, proteini, broj sastojaka. Pre klasterovanja podaci su skalirani kako bi se eliminisao uticaj različitih opsega vrednosti.

Radi bolje interpretabilnosti i smanjenja dimenzionalnosti, primenjena je Principal Component Analysis (PCA). PCA je korišćena za: smanjenje broja dimenzija, uklanjanje korelacija između atributa i vizuelizaciju klastera u 2D prostoru. Analizirana je varijansa objašnjena glavnim komponentama, pri čemu su zadržane komponente koje objašnjavaju najveći deo ukupne varijanse.

Za grupisanje podataka korišćen je algoritam K-Means.

Testirano je više vrednosti parametra *k* (broj klastera), a evaluacija je izvršena pomoću sledećih metrika:

- Silhouette score
- Davies-Bouldin indeks
- Calinski-Harabasz indeks

Na osnovu kombinacije metrika i interpretabilnosti rezultata izabran je optimalan broj klastera.

2.2. Klasterovanje tekstualnih recenzija

Tekstualne recenzije su prethodno obrađene: uklonjeni su prazni zapisi, tekst je normalizovan i primenjena je TF-IDF reprezentacija. TF-IDF transformacija omogućava numeričku reprezentaciju teksta na osnovu značaja reči u okviru celog korpusa.

Nad TF-IDF matricom primenjen je K-Means algoritam sa više testiranih vrednosti parametra *k*. Za svaki klaster izdvojene su najvažnije reči (centroid-based top terms), čime je omogućena interpretacija tematske strukture klastera.

Silhouette score za tekstualne podatke bio je nizak (~0.005), što ukazuje na slabu geometrijsku separabilnost u visoko-dimenzionalnom TF-IDF prostoru.

Međutim, analiza najfrekventnijih termina po klasterima pokazala je smisleno tematsko grupisanje, npr:

- recenzije fokusirane na modifikacije recepta
- recenzije koje naglašavaju jednostavnost pripreme
- izrazi zahvalnosti i pozitivne reakcije
- generički pozitivni komentari

Niska vrednost silhouette metrike je očekivana zbog: kratke forme komentara, visoke homogenosti pozitivnih ocean, ograničenog vokabulara karakterističnog za recepte. Zbog toga je interpretabilnost klastera bila važniji kriterijum od same numeričke metrike.

2.3. Zaključak

Klaster analiza numeričkih podataka pokazala je postojanje strukturnih razlika među receptima na osnovu nutritivnih karakteristika.

Tekstualno klasterovanje, iako sa niskom separabilnošću prema metričkim pokazateljima, otkrilo je tematske obrasce u korisničkim recenzijama.

3. Klasifikacija

Nakon završene faze pretprocesiranja formirani su skupovi podataka pogodni za primenu algoritama nadgledanog učenja. Cilj klasifikacije bio je predviđanje da li recept pripada kategoriji visoko ocenjenih recepata, na osnovu dostupnih numeričkih atributa i karakteristika sastojaka. U tu svrhu definisana je binarna ciljna promenljiva *high_rating*, koja poprima vrednost 1 ukoliko je ocena veća ili jednaka zadatom pragu, odnosno 0 u suprotnom.

Radi detaljnije analize sprovedena su dva različita eksperimenta klasifikacije, koji se razlikuju po tipu ulaznih podataka i nivou agregacije informacija.

3.1. Klasifikacija na nivou korisničkih recenzija

U prvom eksperimentu klasifikacija je realizovana nad skupom *df_all_reviews*, gde svaki red predstavlja jednu korisničku interakciju sa receptom. Na osnovu atributa *rating* formirana je nova binarna promenljiva *high_rating*, pri čemu su ocene veće ili jednake 4.5 označene kao visoke.

Kao ulazne karakteristike korišćeni su numerički atributi koji opisuju recept, uključujući trajanje pripreme, broj koraka, broj sastojaka, kao i nutritivne vrednosti poput kalorija, masti, šećera, natrijuma i proteina. Podaci su zatim podeljeni na trening i test skup u odnosu 70:30, uz stratifikaciju po ciljnoj promenljivoj kako bi se očuvala raspodela klasa.

Za modelovanje su korišćena dva algoritma ansambl učenja:

- Random Forest, koji kombinuje više stabala odlučivanja radi stabilnijih predikcija,

- Gradient Boosting, koji iterativno poboljšava performanse modela fokusirajući se na teže klasifikovane primere.

Evaluacija modela izvršena je pomoću metrike tačnosti i konfuzione matrice. Random Forest model ostvario je tačnost od približno 0.70, dok je Gradient Boosting postigao blago bolje rezultate, sa tačnošću oko 0.72. Analiza konfuzione

matrice pokazuje da modeli imaju tendenciju da češće predviđaju klasu visoke ocene, što je očekivano s obzirom na neravnomernu raspodelu ocena u datasetu, gde dominiraju visoke vrednosti.

3.2. Klasifikacija na nivou recepata sa One-Hot kodiranim sastojcima

Drugi eksperiment klasifikacije sproveden je nad agregiranim skupom *df_recipes_reduced_ingredients*, gde svaki red predstavlja jedan recept sa prosečnom ocenom i binarnim indikatorima sastojaka dobijenim One-Hot kodiranjem. Ciljna promenljiva *high_rating* definisana je na osnovu prosečne ocene recepta.

U ovom pristupu iz skupa atributa uklonjeni su identifikatori, tekstualni opisi i ostale nerelevantne kolone, dok su zadržane numeričke karakteristike i indikator prisustva sastojaka. Time je formiran visokodimenzionalni skup podataka koji omogućava modelu da uči obrasce vezane za kombinacije sastojaka.

Nakon podele na trening i test skup primenjen je Random Forest klasifikator sa standardnim parametrima. Model je ostvario tačnost približno 0.63, što je niže u odnosu na prvi eksperiment. Analiza klasifikacionog izveštaja pokazuje da model ima visoku preciznost i odziv za klasu visoko ocenjenih recepata, ali znatno slabije rezultate za klasu niskih ocena. Ovakvo ponašanje može se objasniti izraženom neravnotežom klasa i velikom dimenzionalnošću prostora atributa, koja otežava razlikovanje manje zastupljene klase.

3.3. Zaključak

Upoređivanjem rezultata dva eksperimenta može se uočiti da modeli trenirani nad agregiranim numeričkim atributima postižu stabilnije performanse u odnosu na modele koji koriste veliki broj binarnih indikatora sastojaka. Iako One-Hot reprezentacija omogućava detaljan opis recepata, visoka dimenzionalnost i retkost pojedinih sastojaka uvode dodatni šum koji može negativno uticati na generalizaciju modela.

Sa druge strane, nutritivni atributi i osnovne karakteristike recepta pokazuju se kao informativniji prediktori za procenu da li će recept biti visoko ocenjen. Ovi rezultati

ukazuju na značaj pažljive selekcije atributa i balansiranja kompleksnosti modela u radu sa realnim, heterogenim skupovima podataka.